

The background of the slide is a light gray gradient. It is decorated with numerous realistic water droplets of various sizes. Some droplets are at the top left, some are scattered in the middle, and a larger cluster of droplets is on the right side. The droplets have highlights and shadows, giving them a three-dimensional appearance.

WORKSHOP – ÚVOD DO STROJOVÉHO UČENÍ

ONDŘEJ JANEČEK, 21.6.2026


OBARVOVÁNÍ ČERNOBÍLÝCH FOTOGRAFIÍ POMOCÍ NEURONOVÝCH SÍTÍ

- **MOTIVACE**

- HISTORICKÉ FOTOGRAFIE ČASTO EXISTUJÍ POUZE V ČERNOBÍLÉ PODOBĚ.
- RUČNÍ OBARVOVÁNÍ JE ČASOVĚ NÁROČNÉ.
- CÍLEM JE AUTOMATICKY ODHADNOUT BARVY Z JASOVÉ INFORMACE.

- **ZADÁNÍ**

- VSTUP: JASOVÝ KANÁL **L** V BAREVNÉM PROSTORU LAB.
- VÝSTUP: BAREVNÉ KANÁLY **A** A **B**.
- VÝSLEDKEM JE REKONSTRUKCE BAREVNÉHO OBRÁZKU.
- PROČ LAB: U RGB BY MODEL MUSEL PREDIKOVAT VŠECHNY TŘI KANÁLY NAJEDNOU. V LAB PROSTORU JE ALE JASOVÁ INFORMACE ODDĚLENA OD BAREVNÉ INFORMACE.



- **DATASET:**

- CIFAR-10 ROZLIŠENÍ: 32×32 PX
- BAREVNÝ PROSTOR: LAB
- FRAMEWORK: PYTORCH
- HW: GOOGLE COLAB (GPU)
- METRIKY: MSE, MAE

BASELINE

- **MEAN COLOR BASELINE**

- **PRINCIP**

- SPOČÍTÁ PRŮMĚRNOU HODNOTU KANÁLŮ A A B.
- TOUTO BARVOU VYPLNÍ CELÝ OBRÁZEK.


- **VÝHODY**

- EXTRÉMNĚ JEDNODUCHÁ METODA.
- POSKYTUJE REFERENČNÍ ÚROVEŇ VÝKONU.

- **NEVÝHODY**

- NEROZLIŠUJE OBJEKTY.
- NEVYTVÁŘÍ LOKÁLNÍ BAREVNÉ DETAILS.

- PŘESTOŽE MEAN COLOR BASELINE VYUŽÍVÁ INFORMACI ZE SKUTEČNÝCH BAREVNÝCH KANÁLŮ A A B, NELZE JI POVAŽOVAT ZA ZCELA NEREÁLNÝ REFERENČNÍ PŘÍSTUP. PŘI RUČNÍM OBARVOVÁNÍ HISTORICKÝCH FOTOGRAFIÍ BY ČLOVĚK PRAVDĚPODOBNĚ TAKÉ VYCHÁZEL Z PODOBNÝCH BAREVNÝCH REFERENCÍ, NAPŘÍKLAD Z JINÝCH FOTOGRAFIÍ STEJNÉHO OBJEKTU, OBDOBÍ NEBO PROSTŘEDÍ. BASELINE TAK DO URČITÉ MÍRY SIMULUJE SITUACI, KDY JE K DISPOZICI EXTERNÍ ZNALOST O TYPICKÝCH BARVÁCH DANÉ SCÉNY.




ARCHITEKTURY NEURONOVÝCH SÍTÍ

- **SIMPLE CNN**
- **ZVOLENA JAKO „DRUHOTNÁ BASELINE“ PRO POROVNÁNÍ**

- 3 KONVOLUČNÍ VRSTVY.
- PREDIKCE KANÁLŮ A A B.
- VYUŽÍVÁ LOKÁLNÍ OBRAZOVÉ INFORMACE.

- **U-NET**

- ENCODER + DECODER.
- SKIP CONNECTIONS.
- KOMBINACE LOKÁLNÍHO A GLOBÁLNÍHO KONTEXTU.






VÝSLEDKY PROVEDENÝCH EXPERIMENTŮ

			MSE					MAE				
	Train size	Doba běhu	Baseline	CNN	U-NET	U-NET - Baseline	U-NET - CNN	Baseline	CNN	U-NET	U-NET - Baseline	U-NET - CNN
WS1	100	1 min	0,005825	0,010022	0,010383	0,004558	0,000361	0,052863	0,068848	0,071927	0,019064	0,003079
WS2	300	7 min	0,005714	0,012725	0,012611	0,006897	-0,000114	0,052042	0,078625	0,079076	0,027034	0,000451
WS3	1 000	13 min	0,005008	0,009668	0,009252	0,004244	-0,000416	0,047478	0,066042	0,064900	0,017422	-0,001142
WS4	2 000	37 min	0,005297	0,010660	0,009518	0,004221	-0,001142	0,049331	0,070212	0,067025	0,017694	-0,003187
WS5	5 000	80 + min	0,005100	0,009761	0,009249	0,004149	-0,000512	0,048077	0,066860	0,065509	0,017432	-0,001351

- OD VELIKOSTI TRÉNOVACÍ MNOŽINY 1 000 OBRÁZKŮ ZAČAL U-NET KONZISTENTNĚ DOSAHOVAT LEPŠÍCH VÝSLEDKŮ NEŽ SIMPLE CNN.
- OD WS2 BYL IMPLEMENTOVÁN JEDNODUCHÝ EARLY STOPPING A UKLÁDÁNÍ NEJLEPŠÍHO MODELU PODLE VALIDAČNÍ CHYBY. VÝSLEDKY UKAZUJÍ, ŽE S ROSTOUCÍ VELIKOSTÍ TRÉNOVACÍ MNOŽINY ZAČÍNÁ ARCHITEKTURA U-NET DOSAHOVAT LEPŠÍCH VÝSLEDKŮ NEŽ SIMPLE CNN. ROZDÍL JE NEJVÝRAZNĚJŠÍ PŘI VELIKOSTI TRÉNOVACÍ MNOŽINY 2000 OBRÁZKŮ, KDE U-NET DOSAHUJE PŘIBLIŽNĚ O 11 % NIŽŠÍ MSE NEŽ SIMPLE CNN.

GRAFICKÉ VÝSLEDKY WS5

ZLEVA: PŮVODNÍ RGB | VSTUPNÍ L | MEAN BASELINE | SIMPLE CNN | U-NET



DISKUSE

- **POZOROVÁNÍ**

- U-NET DOSAHOVAL MÍRNĚ LEPŠÍCH VÝSLEDKŮ NEŽ SIMPLE CNN.
- S ROSTOUCÍM POČTEM TRÉNOVACÍCH DAT SE VÝSLEDKY ZLEPŠOVALY.
- NEJLEPŠÍ MSE DOSÁHLA MEAN BASELINE.

- **OMEZENÍ**

- BASELINE VYUŽÍVÁ INFORMACI ZE SKUTEČNÝCH BAREVNÝCH KANÁLŮ.
- DATASET CIFAR-10 OBSAHUJE POUZE MALÉ OBRÁZKY 32×32 PX.
- BAREVNOST NĚKTERÝCH OBJEKTŮ NELZE JEDNOZNAČNĚ ODHADNOUT POUZE Z JASU.

- SIMPLE CNN I U-NET BYLY TRÉNOVÁNY SE STEJNOU ZTRÁTOVOU FUNKCÍ (MSE), STEJNÝM OPTIMALIZÁTOREM ADAM A STEJNÝM VSTUPEM (L KANÁL).
- VÝSLEDKY POTVRZUJÍ, ŽE KVALITA MODELU JE VÝRAZNĚ OVLIVNĚNA VELIKOSTÍ TRÉNOVACÍ MNOŽINY.

MOŽNÁ VYLEPŠENÍ

- **VÍCE DAT**

- VĚTŠÍ TRÉNOVACÍ MNOŽINA
- VYŠŠÍ ROZLIŠENÍ

- **LEPŠÍ MODELÝ**

- VISION TRANSFORMER (VIT)
- CLIP
- MODERNÍ COLORIZATION MODELÝ

- **VYUŽITÍ KONTEXTU**

- TYP SCÉNY
- GEOGRAFICKÁ LOKALITA
- OBDOBÍ VZNIKU FOTOGRAFIE
- SEGMENTACE OBJEKTŮ
- ZAŘÍZENÍ POUŽITÉ PRO SNÍMEK

ZÁVĚR A ZDROJE

- CÍLEM BYLO NAVRHNOUT MODEL PRO AUTOMATICKÉ OBARVOVÁNÍ ČERNOBÍLÝCH FOTOGRAFIÍ.
- EXPERIMENT UKÁZAL, ŽE ARCHITEKTURA U-NET DOSAHUJE PŘI VĚTŠÍCH TRÉNOVACÍCH MNOŽINÁCH LEPŠÍCH VÝSLEDKŮ NEŽ JEDNODUCHÁ CNN. SOUČASNĚ SE POTVRDILLO, ŽE MNOŽSTVÍ TRÉNOVACÍCH DAT MÁ ZÁSADNÍ VLIV NA KVALITU OBARVENÍ. DALŠÍ ZLEPŠENÍ LZE OČEKÁVAT PŘI POUŽITÍ VĚTŠÍCH DATASETŮ, VYŠŠÍHO ROZLIŠENÍ A MODERNĚJŠÍCH ARCHITEKTUR.

- **DATASET**

- [CIFAR-10 DATASET](#)
- [TORCHVISION CIFAR-10 DOCUMENTATION](#)

- **NEURONOVÉ SÍTĚ**

- [DEEP LEARNING \(GOODFELLOW, BENGIO, COURVILLE\)](#)
- [PYTORCH DOCUMENTATION](#)

- **U-NET**

- [U-NET: CONVOLUTIONAL NETWORKS FOR BIOMEDICAL IMAGE SEGMENTATION \(RONNEBERGER ET AL., 2015\)](#)

- **COLORIZATION**

- [COLORFUL IMAGE COLORIZATION \(ZHANG ET AL., 2016\)](#)

- **BUDOUCÍ ROZŠÍŘENÍ**

- [AN IMAGE IS WORTH 16X16 WORDS: VISION TRANSFORMER \(DOSOVITSKIY ET AL., 2020\)](#)
- [LEARNING TRANSFERABLE VISUAL MODELS FROM NATURAL LANGUAGE SUPERVISION \(CLIP\)](#)